

Machine Learning Classification Model: DATA-DRIVEN APPROACH TO PREDICT & REDUCE HOTEL ROOM VACANCY IN PORTUGAL

Predict. Prevent. Profit.

BOOK NOW

START SLIDE

Presented by **GABRIELLA DAVINTIA & RIZAN PRADIYA**

8 MARET 2026

EXECUTIVE SUMMARY

Proyek ini bertujuan mengembangkan model machine learning berbasis klasifikasi untuk memprediksi kemungkinan pembatalan pemesanan hotel.

Tingkat pembatalan dipengaruhi oleh berbagai faktor, seperti:

- Waktu Pemesanan
- Durasi Menginap
- Jumlah Tamu
- Tipe Hotel

Predict kemungkinan pembatalan pemesanan hotel menggunakan XGBoost Model untuk menunjukkan performa terbaik

Model akhir digunakan untuk memprediksi apakah suatu booking akan dibatalkan atau tidak

TABLE OF CONTENT

1. Introduction
2. Data Understanding
3. Exploratory Data Analysis (EDA)
4. Modeling
5. Conclusion
6. Recommendation

INTRODUCTION

CONTEXT

- Industri perhotelan merupakan sektor penting dalam industri pariwisata.
- Peningkatan mobilitas masyarakat dan perjalanan bisnis/wisata meningkatkan kompleksitas pengelolaan pemesanan hotel.
- Pengelolaan reservasi dipengaruhi oleh berbagai faktor operasional dan perilaku tamu.
- Diperlukan analisis pola pemesanan untuk mendukung pengambilan keputusan yang lebih efektif.

PROBLEM STATEMENT

- Tingginya tingkat pembatalan dan fluktuasi permintaan memengaruhi tingkat hunian.
- Kesulitan dalam memprediksi pembatalan dapat menyebabkan inefisiensi operasional dan kehilangan pendapatan.

INTRODUCTION

GOALS

- Menganalisis faktor-faktor utama yang memengaruhi perilaku pemesanan dan pembatalan hotel menggunakan data historis.
- Membangun model machine learning berbasis klasifikasi untuk memprediksi kemungkinan pembatalan pemesanan hotel.
- Membantu pihak hotel dalam mengoptimalkan pengelolaan reservasi, tingkat hunian, dan strategi harga berdasarkan prediksi berbasis data.

ANALYTICAL APPROACH

- Data Understanding
- Exploratory Data Analysis (EDA)
- Data Preprocessing
- Model Development
- Model Training and Validation
- Model Selection and Optimization
- Model Interpretation

INTRODUCTION

METRIC EVALUATION

- ROC-AUC
- Recall (%)
- Precision (%)
- Confusion Matrix
 - TP (True Positive): Pembatalan yang berhasil terdeteksi dengan benar.
 - TN (True Negative): Pemesanan yang diprediksi tidak dibatalkan dan memang benar-benar tidak dibatalkan.
 - FN (False Negative): Pembatalan yang tidak terdeteksi.
 - FP (False Positive): Pemesanan yang diprediksi batal namun sebenarnya tidak dibatalkan.
- Evaluasi Finansial
 - Penghematan (Savings) dalam USD (\$)
 - Return on Investment (ROI %)

STAKEHOLDERS

- Manajemen Hotel
- Revenue Management Team
- Operational & Front Office Team

DATA UNDERSTANDING

DATA DICTIONARY

Kategorik : 11

Numerik : 19

Binary : 2


08

hotel	Jenis hotel (City Hotel atau Resort Hotel).	is_repeated_guest	Menunjukkan apakah tamu merupakan pelanggan tetap.
is_canceled	Status pembatalan pemesanan (1 = dibatalkan, 0 = tidak dibatalkan).	previous_cancellations	Jumlah pembatalan yang pernah dilakukan sebelumnya.
lead_time	Jumlah hari antara tanggal pemesanan dan tanggal kedatangan.	previous_bookings_not_canceled	Jumlah pemesanan sebelumnya yang tidak dibatalkan.
arrival_date_year	Tahun kedatangan tamu.	reserved_room_type	Tipe kamar yang dipesan.
arrival_date_month	Bulan kedatangan tamu.	assigned_room_type	Tipe kamar yang diberikan saat check-in.
arrival_date_week_number	Minggu ke-berapa dalam tahun saat kedatangan.	booking_changes	Jumlah perubahan pada pemesanan.
arrival_date_day_of_month	Tanggal kedatangan dalam bulan.	deposit_type	Jenis deposit pada pemesanan.
stays_in_weekend_nights	Jumlah malam menginap pada akhir pekan.	agent	Kode agen yang melakukan pemesanan (jika ada).
stays_in_week_nights	Jumlah malam menginap pada hari kerja.	company	Kode perusahaan yang melakukan pemesanan (jika ada).
adults	Jumlah tamu dewasa dalam pemesanan.	days_in_waiting_list	Jumlah hari pemesanan berada dalam daftar tunggu.
children	Jumlah tamu anak-anak dalam pemesanan.	customer_type	Tipe pelanggan berdasarkan karakteristik pemesanan.
babies	Jumlah bayi dalam pemesanan.	adr	Average Daily Rate (tarif rata-rata per malam).
meal	Tipe paket makan yang dipilih tamu.	required_car_parking_spaces	Jumlah tempat parkir yang dibutuhkan.
country	Negara asal tamu.	total_of_special_requests	Jumlah permintaan khusus dari tamu.
market_segment	Segmen pasar pemesanan.	reservation_status	Status akhir pemesanan (Check-Out, Canceled, No-Show).
distribution_channel	Saluran distribusi pemesanan.	reservation_status_date	Tanggal terakhir status pemesanan diperbarui.


EXPLORATORY DATA ANALYSIS

— Lebih banyak guest booking di City Hotel dan lebih banyak guest yang tidak cancel booking


Distribution of Bookings by Hotel Type



Distribution of Booking Cancellations




HEATMAP KORELASI DATA NUMERIK




AVERAGE DAILY RATE

- ADR meningkat signifikan dari Januari hingga Agustus, menunjukkan adanya pola musiman (peak season di pertengahan tahun)
- Bulan Agustus memiliki ADR tertinggi, artinya hotel bisa mengenakan harga premium saat demand tinggi.
- Penurunan tajam terjadi setelah Agustus (September–November), menunjukkan low season.
- November adalah titik ADR terendah setelah peak season, berpotensi butuh strategi promosi atau diskon.



CANCELLATION RATE BY CUSTOMER TYPE




- Customer tipe Group memiliki tingkat pembatalan tertinggi → segmen paling berisiko.
- Transient-Party memiliki cancellation rate terendah, sehingga lebih stabil.
- Contract dan Transient memiliki tingkat pembatalan yang relatif mirip (sekitar 40%).
- Segmen Group perlu strategi khusus seperti:
 - Deposit lebih besar
 - Kebijakan pembatalan lebih ketat
 - Konfirmasi ulang sebelum tanggal check-in

DATA PREPROCESSING

DROP COLUMNS

16



STEP BY STEP

1. Data splitting

- Drop columns

2. Train and test splitting

- Test size = 0.2

3. Encoding

- Data Kategorik

4. Scaling

- Data Numerik

Pipeline

- X_train_tree shape: (95512, 71)
- X_train_scaled shape: (95512, 71)

Model yang diuji

- Random Forest: Tree (tanpa scaler)
- XGBoost: Tree (tanpa scaler)
- LightGBM: Tree (tanpa scaler)
- Logistic Regression: Scaled (StandardScaler)

MODELING

HASIL BENCHMARKING

Model	ROC-AUC	Recall (%)	Precision (%)	TP (Kamar Diselamatkan)	FN (Kamar Kosong)	FP (Salah Prediksi)	Penghematan (\$)	ROI (%)
Random Forest	0.89	72.79	75.63	6,438	2,407	2,074	1,859,863.38	151.5
XGBoost	0.91	89.07	65.44	7,878	967	4,160	2,073,553.66	204.5
LightGBM	0.91	78.89	76.66	6,978	1,867	2,124	2,031,323.51	192.33
Logistic Regression	0.87	75.36	69.52	6,666	2,179	2,923	1,829,003.29	145.33

Peringkat	Model	Recall (%)	Penghematan (\$)	ROI (%)
1	XGBoost	89.07	2,073,554	204.5
2	LightGBM	78.89	2,031,324	192.33
3	Random Forest	72.79	1,859,863	151.5
4	Logistic Regression	75.36	1,829,003	145.33

Peringkat	Model	Recall (%)	FN (Kamar Kosong)	Penghematan (\$)
1	XGBoost	89.07	967	2,073,554
2	LightGBM	78.89	1,867	2,031,324
3	Logistic Regression	75.36	2,179	1,829,003
4	Random Forest	72.79	2,407	1,859,863

Model Terbaik: XGBoost

Recall: 89.07%

Penghematan: \$2,073,554

ROI: 204.5%

CLASSIFICATION REPORT

Untuned

Class	Precision	Recall	F1-Score	Support
0	0.92	0.72	0.81	15,033
1	0.65	0.89	0.75	8,845

- TN: 10873
- FP: 4160
- FN: 967
- TP: 7878

	Predicted 0	Predicted 1
Actual 0	10,873	4,160
Actual 1	967	7,878

ROC-AUC Score: 0.9114

- True Negative → Aman
- False Postive → Salah Prediksi
- False Negative → Kamar Kosong
- True Positive → Kamar Diselamatkan

Tuned

Class	Precision	Recall	F1-Score	Support
0	0.94	0.54	0.69	15,033
1	0.55	0.94	0.69	8,845

- TN: 8123
- FP: 6910
- FN: 505
- TP: 8340

	Predicted 0	Predicted 1
Actual 0	8,123	6,910
Actual 1	505	8,340

Recall (%): 89.07%

Precision (%): 65.44%


Tanpa Model - Loss (\$): \$3,087,496.89

Dengan Model - Cost (\$): \$1,013,943.22

Penghematan (\$): \$2,073,553.66

ROI (%): 204.50%

FEATURE IMPORTANCES



SIMULASI BISNIS

Misalkan dalam satu periode terdapat:

- 10.000 booking
- 4.000 benar-benar cancel
- 6.000 tidak cancel

1. Tanpa Model

- Semua 4.000 booking cancel menjadi kamar kosong
 - Hotel kehilangan seluruh potensi revenue dari booking tersebut
 - Tidak ada mekanisme mitigasi
 - Tidak ada optimasi overbooking
 - Tidak ada early intervention
- Hotel akan sepenuhnya reaktif.

2. Dengan Model (Baseline)

Dengan recall 89%:

- 3.560 booking cancel berhasil terdeteksi lebih awal
- Hanya 440 booking yang lolos dan tetap menjadi kamar kosong

Model secara signifikan mengurangi potensi kamar kosong.

Dari hasil evaluasi aktual:

- FN (kamar kosong yang tidak terdeteksi) = 967
- TP (kamar yang berhasil diselamatkan) = 7.878
- FP (false alarm) = 4.160

Namun secara finansial:

- **Total penghematan = \$2.073.553**
- **ROI = 204%**

Setiap \$1 biaya intervensi menghasilkan sekitar \$2 keuntungan.

Ini menunjukkan bahwa meskipun ada false alarm, secara agregat model tetap sangat menguntungkan.

CONCLUSION

Berdasarkan hasil evaluasi model Baseline, kita dapat menyimpulkan bahwa apabila hotel menggunakan model ini untuk mendeteksi tamu yang berisiko melakukan pembatalan, maka model mampu memberikan dampak finansial yang signifikan.

Model memiliki:

- Recall = 89.07%
- Precision = 65.44%
- ROI = 204.5%
- Penghematan = \$2.07 juta

REKOMENDASI BISNIS

1. Terapkan Dual Pricing Strategy

- Non-refundable (lebih murah 10-20%) → tidak bisa dibatalkan
- Refundable (lebih mahal) → fleksibel dengan syarat tertentu

2. Implementasi Early Warning System

Gunakan model prediksi untuk mengidentifikasi booking berisiko tinggi batal dan lakukan tindakan preventif

- reminder
- konfirmasi ulang
- penyesuaian kebijakan deposit

3. Monitoring & Model Updating

Lakukan evaluasi berkala terhadap performa model dan update model sesuai perubahan pola pasar.

4. Evaluasi Finansial Berkala

Hitung dampak penghematan dan ROI untuk memastikan implementasi model benar-benar memberikan nilai bisnis.



TERIMA KASIH



Gabriella Davintia

Rizan Pradiya



Github